

在反卷积网络中引入数值解可视化卷积神经网络

俞海宝 沈 琦 冯国灿

(中山大学数学学院 广州 510275)

摘 要 经典的反卷积可视化模型通过反池化、反激活、反卷积将特征图像还原至原图像空间,可视化网络节点从输入图像学习到的特征,有助于探究卷积神经网络运行良好的机制,但是由于采用近似处理,还原特征不明显。本研究引入数值求解方法来代替原模型中直接用卷积核的反转近似反卷积核的方法。先构造数据集:随机生成大小、形状、位置不一的结构简单、角点特征明显的三角形和矩形,用于组成层次结构逐渐复杂的数据集,并利用该数据集测试模型的可视化效果。实验表明,改进后的可视化模型提取的特征更明显,引入的噪音更少,可以更为精确地将激活网络节点从原图像学习的特征可视化。在更大的数据库上进行实验来验证结果,并利用这种结果进一步探究准确率与网络结构之间存在何种关系。

关键词 卷积神经网络,可视化,反卷积,数值求解

中图法分类号 TP301.6 **文献标识码** A

Introduce Numerical Solution to Visualize Convolutional Neuron Networks Based on Numerical Solution

YU Hai-bao SHEN Qi FENG Guo-can

(School of Mathematics, Sun Yat-sen University, Guangzhou 510275, China)

Abstract Zeiler's visualization model restore the feature maps to original image space, by unpooling and deconvolution, to visualize what the node learn from the image. It helps to research the convolutional neural networks mechanism, but the result is not apparent for the vague method. Based on the Zeiler's deconvolutional visualization model, numerical solution method was introduced to replace the vague method that just use convolutional kernel. The database was constructed firstly. The triangle and rectangle was generated with random size, shape and location, which have simple structure and apparent vertex. Based on the database, we constructed hierarchy database and took out experiment. The experiment results show that the improvement model extracts more apparent features and has less noise, which has more precise result. Experiment on bigger database was taken to verify our result, and the result to guide how to construct the network's structure.

Keywords Convolutional neural networks(CNN), Visualization, Deconvolution, Numerical solution

CNN 是实现深度学习的主要模型,由传统的人工神经网络发展而来,主要由卷积层(C)与下采样层(S)交替重复出现来构建网络结构,其中卷积层用来提取输入数据的局部特征,下采样层用来对其上一层提取的数据进行缩放映射,以减少训练数据量^[1],并采用 BP 来训练网络^[2]。在 2012 年的 ImageNet 大赛上, Hinton 的研究小组采用基于 CNN 的深度学习并以超过第二名 10% 的准确率赢得了比赛,利用深度学习在 LWF 库上的人脸识别准确率也达到了 99.47%^[3]。深度学习在计算机视觉领域引发了巨大的震动。同时在工业界,谷歌和百度都发布了新的基于图像内容的搜索引擎,它将 Hinton 在 ImageNet 竞赛中用到的深度学习模型应用在各自的数据上,发现图像搜索的准确率得到了大幅度的提高^[4]。目前, CNN 在行人检测^[5]和人脸识别^[6]等领域得到了广泛应用。CNN 虽然在图像处理领域已经取得了巨大的成功,但其机制目前尚不明确,具体表现为以下 3 点:1) Nguyen^[7] 的研究指出,通过对原始图像添加人为的微小扰动,可以使得深度学习模型将人眼看起来没有区别的图像进行误判,这样人为

构造的对抗样本可以“骗过”网络,引发了对深度学习的信任危机^[8];2) 目前发表的、达到相当精度的深度学习网络的层数往往达到了上百层甚至更深^[4],模型训练随着层数的增加而变得异常繁琐,且整个调参过程需要相当丰富的经验^[9],实际上尚未有理论证明分类的准确率会随着深度的增加而增加;3) 训练庞大的神经网络往往需要大量的样本,这使得深度学习无法胜任小样本学习任务。本质上来说,上述这些问题的解决都建立在对深度学习的机理进行探究的基础上。探索深度学习的机理是为了利用训练样本确定一个不冗余且稳定的深度学习网络,一种方案是直接对深度网络进行数学机理的探究^[1],但是这个方法相对复杂并且还存在一些局限性;另一种相对直观的解决方案就是将网络节点可视化,通过对深度学习网络节点进行可视化来理解该节点所对应的特征,从而帮助探究 CNN 运行机理,最终实现对深度网络结构和内部参数调整的指导。

网络节点可视化最基本的模型是纽约大学 Zeiler 所提出的^[10-11]。在该模型中, Zeiler 利用反卷积网络通过信号对某

本文受国家自然科学基金(61272338)资助。

俞海宝(1994—),男,主要研究方向为数字图像处理, E-mail: yuhb3@mail2.sysu.edu.cn; 沈琦,女,副研究员,主要研究方向为统计模式识别、数字图像处理; 冯国灿,男,教授,主要研究方向为模式识别和图像处理。

个特征图像向后传播,经过反池化、反激活、反卷积,最终还原至原图像空间。但是由于 Zeiler 的反卷积可视化模型中反卷积核是用卷积核的反转近似得到的,这种模糊复原在通过 average-pooling 层后会引入大量无关信息,因此可视化效果并不理想。本文在 Zeiler 模型基础上,用数值求解的方法来替代原模型反卷积过程中用原卷积核近似复原,实验结果表明,本方法可视化后更利于直观理解提取的特征,且引入的噪音更少。

此外,本研究进一步利用改进的可视化工具进一步探究 CNN 的分级学习机制。CNN 取得良好的效果被认为是由于该方法是按照人脑分级学习机制提取特征的^[12]。针对此理论,本文针对性地构造了具有层次结构的三角形和矩形等具有结构简单、角点特征明显等性质的图形数据集,并利用该数据集和改进的可视化工具,通过实验结果观察到准确率高的 CNN 的确逐层提取特征,符合分层学习机制,这对我们利用图像集的层次属性调整网络结构构造具有一定的启发指导作用。

1 相关工作

窥探卷积神经网络内部机理,需要理解网络节点如何学习特征。一种是直接显示特征图像,如图 1(b)所示,但是该方法无法判断节点从输入图像学习何种特征。另一种是利用信号向后传播的反卷积网络将特征图像还原到原图像空间,如图 1(c)所示,可直观理解节点学习的特征。




图 1

1.1 反卷积网络

将特征图像还原到原图像空间采用的方法是反卷积网络。经典的反卷积网络模型类似于自编码,利用卷积神经网络无监督地从数据中学习高层次特征^[10]。该模型的工作原理为:给定输入图像和随机初始化的卷积神经网络,将指定层的特征图像向后传播到输入层,得到重构图像 \tilde{x} 。如对于第一层的特征图像,求反卷积核和相应的特征图像 \tilde{z} ,得到重构图像:

$$\tilde{x} = \sum_{i=1}^{n_1} \tilde{z}_i \otimes f_i^1$$

其中, f_i^1 指第一层的第 i 个反卷积核,得到其与输入图像 x 误差尽可能小并保持特征图像的稀疏,即有:

$$\arg \min_{f_i^1} \|x - \tilde{x}\|_2^2 + \sum_{i=1}^{n_1} \|\tilde{z}_i\|_1 \quad (1)$$

然后利用分步迭代的方法求解式(1)中的反卷积滤波器和特征图像。同理对每一层特征图像做同样的处理,便可逐层得到从原图像集中学习到的特征。Zeiler 通过反卷积网络无监督学习到的特征图可以用来表达原图^[13]。

1.2 反卷积可视化模型

在反卷积网络的基础上,对训练好的 CNN,利用水平、垂直翻转后的卷积核作为反卷积核,可通过反池化、反激活、反

卷积等方法将特征图像还原映射到原图像空间^[14],可视化每个节点从输入图像学习到的特征(池化用的是 max-pooling,激活函数为 relu 函数),如图 2 所示。其中反池化是指输入图像前向传播经过 max-pooling 时,记录最大像素值的位置,还原时将像素值赋给记录位置处,其余位置像素置为零;反激活依然采用 relu 函数;反卷积是用卷积核水平垂直旋转近似作为反卷积核。

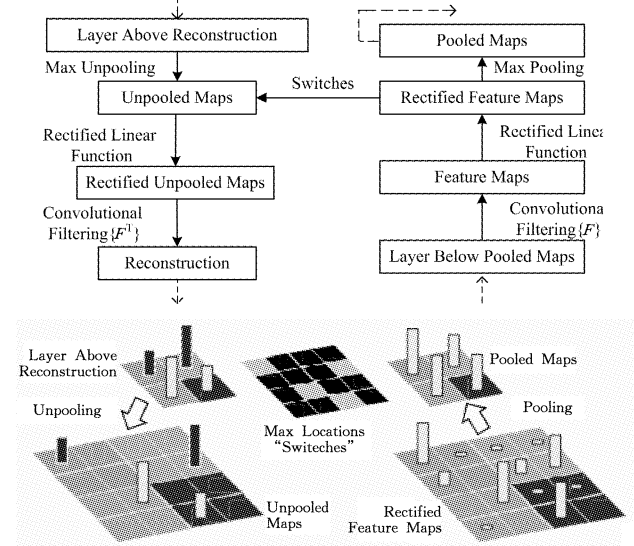


图 2 Zeiler 反卷积可视化模型

其中反卷积操作(DeConv)如下:

由于 CNN 反向传播训练时,预测类标与原类标间的误差函数 E 在 p 处的偏导为: $\partial E / \partial p = \sum_{j=1}^2 (\partial E / \partial z_j^l) \otimes \text{rot}180(f_{i,j})$,因此如图 3 所示,反卷积操作时 Zeiler 直接将 z 与滤波器的转置作卷积,即有 $p_i' = \sum_{j=1}^2 z_j \otimes \text{flip}(\text{flipud}(f_{i,j}))$ 。




图 3 卷积层示意图

重复以上操作,直至将特征图像还原至原图像空间,就得到了每个节点从原图像学习的特征的直观理解。Le Cun 等将这种方法广泛应用于探究机理,并用其来指导改善网络的结构,在 ImageNet 大赛上取得了很好的效果。Jason 利用最大激活原理和正则优化的方法,给定图像和图像通过某个节点后的特征图像,直接求出给定图像与该特征图像关系最大的部分,从而将该节点对应的滤波器映射到原图像空间中,显示结果即该节点从原图像中学习到的特征^[15]。两种方法都可以将某节点从原图像学习到的特征可视化出来。

Zeiler 反卷积方法因简单高效而被广泛应用,但是在反卷积操作(Deconv)过程中采取近似处理信号失真严重,导致可视化特征难以理解,故本文在此过程采用数值解精确还原,减少了不必要的噪音,还原结果更精确,可视化特征更明显。

2 基于数值求解的反卷积可视化

max-pooling 和 average-pooling 是两种常见的池化方法^[16]。average-pooling 更多地保留了背景信息,当采用 avera-

ge-pooling时,Zeiler 反卷积可视化会引入大量无关信息。本文基于 Zeiler 反卷积可视化模型,利用数值求解替代原模型中水平垂直翻转原卷积核近似复原原图像,可针对 average-pooling 的图像提取到更为明显的特征。

UnPooling:如网络中池化采用的是 average-pooling,激活函数依然是 relu 函数,其中反池化(UnPooling)过程如图 4 所示,average-pooling 是取邻域均值作为下一层的输入,UnPooling 则直接将像素值复制到所在邻域。




图 4 average-pooling 与 UnPooling

DeConv:主要求解输入图像中的哪一部分激活了特征图像,即将 z 信号还原至输入层。以图 3 的卷积层为例,求解输入层的 p' ,使得卷积后与 z 的误差尽可能小,即 z 被该部分激活。求解公式如下:

$$\min \left\| \sum_{i=1}^3 p'_i \otimes f_{i,j} - z_j \right\|_2^2$$

另, p' 需与原输入图像 p 保持相关性和稀疏性,故求解如下:

$$\min E = \frac{1}{2} \left\| \sum_{i=1}^3 p'_i \otimes f_{i,j} - z_j \right\|_2^2 + \frac{\lambda}{2} \sum_{i=1}^3 \| p'_i - p_i \|_2^2 + \frac{\beta}{2} \sum_{i=1}^3 \| p'_i \|_2^2 \quad (2)$$

利用梯度下降法求解式(2),即:

$$p' \leftarrow p' - \alpha * \partial E(p') / \partial p' \quad (3)$$

其中, α 为迭代步长,且

$$\frac{\partial E}{\partial p_k} = \sum_{i=1}^{K-1} (p'_i \otimes k_{i,j} - z_j) \otimes \text{rot}180^\circ(k_{k,j}) + \frac{\lambda}{2} (p'_k - p_k) + \frac{\beta}{2} p'_k \quad (4)$$

若此时希望将整层的 z 还原到下采样层,则需求解:

$$\min E = \frac{1}{2} \sum_{j=1}^2 \left\| \sum_{i=1}^3 p'_i \otimes f_{i,j} - z_j \right\|_2^2 + \frac{\lambda}{2} \sum_{i=1}^3 \| p'_i - a_i \|_2^2 + \frac{\beta}{2} \sum_{i=1}^3 \| p'_i \|_2^2 \quad (5)$$

对其求偏导得到

$$\frac{\partial E}{\partial p_k} = \sum_{j=1}^2 \left(\sum_{i=1}^3 p'_i \otimes k_{i,j} - z_j \right) \otimes \text{rot}180^\circ(k_{k,j}) + \frac{\lambda}{2} (p'_k - a_k) + \frac{\beta}{2} p'_k \quad (6)$$

通过数值来求解输入图像中的哪一部分激活了特征图像,而不是直接利用原卷积核的反转近似处理,这便是本文提出的模型与原模型的不同之处。

基于数值求解的反卷积可视化算法的步骤如算法 1 所示。

算法 1 基于数值求解的反卷积可视化算法

将图像 x 输入训练好的卷积神经网络 CNN,可视化第 1 层第 j 个特征图像。

Require: 正则项权重参数 λ 和 β , 步长 α

step1 对当前特征图像进行处理

1. 利用 UnPooling 将特征图像还原到卷积层
2. 利用 Deconv 中式(2)~式(4)求解 p' , 将信号还原到 Pooling 层

step2 从第 1-1 层逐层向后复原信号

1. if 当前层是下采样层
2. for $i=1$; outputmaps 上一层的节点数
3. 利用 UnPooling 将特征图像还原到卷积层
4. else if 当前层 layers=1-1 并且第 1 层是下采样层
5. 利用 UnRectified 将特征图像还原到 z_j
6. 利用 Deconv 中式(2)、式(5)求解 p'
7. else
8. 利用 UnRectified 将特征图像还原到 z_j
9. 利用式(2)、式(6)求解 p'

step3 最后得到的 p' , 即特征图像 z 利用数值求解可视化后的复原图像。显示该特征图像和可视化后的复原图像, 并进行相互比较

3 实验效果及机理探究

3.1 数据集介绍

基础数据集:三角形和矩形结构简单、特征明显,随机生成 5000 个大小、形状、位置、旋转方向不一的三角形和矩形的 28×28 维图像,部分图像如图 5 所示。




图 5 基础数据集

数据集 1:用于比较模型可视化效果。随机从基础数据集中选取 2000 个样本组成训练图像,选取 1000 个样本组成测试图像,依形状分为三角形和矩形两类。

数据集 2:用来探究 CNN 分级学习机制。随机从基础数据集中选取 4 个训练图像组成大小为 56×56 的图像,其中训练图像 2000 个,测试图像 1000 个。依据不同位置选取的图像形状的不同,将类标分为 $2^4=16$ 类,部分图像如图 6 所示。相比于数据集 1,数据 2 具有更高的层次结构。




图 6 从数据集 2 中随机选取 4 幅图像

3.2 实验效果

随机从数据集 1(见图 5)中选取某个图像作为输入图像,好的反卷积可视化结果图像应与原输入图像保持相关性,并且引入的噪声少、特征明显。

利用数据集 1 训练结构为 $\{3,4\}$ (即第一层 3 个节点、第二层 4 个节点)的 CNN,训练次数为 50 次。从数据集 1 中随

机选取一个矩形图像,如图 7(a)所示,分别用 Zeiler 的模型和改进的数值求解模型可视化第二层特征图像,如图 7(b)所示,得到的结果如图 8 所示。




图 7




图 8

从图 7、图 8 可以看出,针对 average-pooling 的 CNN,经典模型因采取近似处理引入了大量噪声,改进模型可视化后与原图像相关度高,且显示的边角特征明显。

改进模型在 Deconv 过程中采用精确的数值求解,因此效率较 Zeiler 模型低,但仍在可接受的范围。表 1 列出了两种模型针对不同 CNN 结构可视化的效率。

表 1 可视化效率的比较

模型结构	Zeiler 模型所需时间/s	改进模型所需时间/s
两层 {5,6}	1.9	13.0
三层 {5,6,6}	2.9	57.8

3.3 探究 CNN 分级提取图像特征

本节利用改进的模型进行探究性实验。CNN 被认为是模仿人脑学习机制,从低层次到高层次分级提取图像特征^[17],因而产生了很好的分类效果。针对此理论,本节利用具有层次结构的数据集 2 和上一节中提出的改进的可视化工具来探究分类准确率高的 CNN 与分级学习之间的关系。

按照分级学习理论,利用数据集 2 训练出的网络,低层次节点学习三角形和四边形的边角特征,高层次节点学习某个三角形或者四边形等部分整体特征,对其他部分没有反应。按照这种思想,在数据集 2 上设计如下实验。

首先选取比 3.2 节中结构大的网络 {6,7,6} 进行训练,训练结果如表 2 所列,训练准确率达到 97.5%。随机将某个测试图像(见图 9,该测试图像含有两个四边形和两个三角形)。输入到网络,并得到各层的特征图像。

表 2 3 个不同结构的 CNN 结构训练 100 次的准确率和所需时间

结构	准确率/%	所需时间/s
{6,7,6}	97.5	1682
{4,3,4}	95.5	788
{2,3}	68.2	412




图 9 从数据集 2 中随机选取的输入图像

图 10 为第一层 4 个特征图像的可视化结果,结果显示,该层节点学习三角形和四边形的边角特征;图 11 为第三层 6 个特征图像的可视化结果,结果显示该层节点只学习某个三角形或者四边形,其余部分影响较小。由此可见,这个 CNN 是分级从原图像提取特征。




图 10 第一层 6 个节点对应的特征图像的可视化结果




图 11 第三层 6 个节点对应的特征图像的可视化结果

上述结构中某些节点没有学习特征或互相重叠,于是将 CNN 结构精简为 {4,3,4}, 准确率为 90.9%。第二层和第三层可视化后的结果如图 12 和图 13 所示。




图 12 第一层 4 个特征图像的可视结果




图 13 第三层 4 个特征图像的可视化结果

图 12 左下和右上对应的节点很明显只被边角激活,图 13 中左下和右下可视化后也只有某部分很明显,由此可见该网络也是按照分级学习提取特征。

进一步将网络精简为 {2,3}。表 2 显示,在该结构下,利用相同的数据集训练的网络准确率大幅下降到 68%,而相应地,选择相同的测试图像,结果显示低层次未有效学习三角形和四边形的边角特征,高层次节点被多个三角形和四边形影响。相比于其他网络结构,该结构网络未从局部到整体学习图像的特征。

由上述实验可知,准确率高的 CNN 按照图像属性分级学习特征,我们可以利用可视化工具寻找准确率高且结构小的网络,以保证训练的效率。

将这个结论推广到其它图像集,如要进行人脸识别时,则可以根据人脸图像的结构层次设计我们想要的准确率高且结构小的网络。

结束语 本文的贡献主要在:首先对国内外 CNN 反卷积可视化研究进行了总结梳理,其次利用数值求解改进了经典反卷积可视化模型,并构造了具有不同结构层次的数据集来探究准确率高的 CNN 与分级学习的关系。实验结果表明,准确率高的网络按照分级提取特征。针对这种结果,可以进一步在更大的数据库上进行试验探究来验证结果,并利用这种结果,进一步探究准确率高与网络结构之间存在的关系。

参考文献

- [1] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324.
- [2] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. *Nature*, 2015, 521(7553): 436-444.
- [3] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[C]// *Advances in Neural Information Processing Systems*. 2012; 1097-1105.
- [4] 王晓刚. 深度学习在图像识别中的研究进展与展望[OL]. <http://chuangsong.me/n/2103247>.
- [5] OUYANG W L, WANG X G. Joint deep learning for pedestrian detection[C]// *ICCV*. New York: IEEE, 2013; 2056-2063.
- [6] CHEN Y N, HAN C C, WANG C T, et al. The application of a convolution neural network on face and license plate detection [C]// *The 18th International Conference on Pattern Recognition*. Hongkong: IEEE, 2006, 4: 552-555.
- [7] NGUYEN A, YOSINSKI J, CLUNE J. Deep neural networks are easily fooled; High confidence predictions for unrecognizable images[C]// *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2015; 427-436.
- [8] FAWZI A, FAWZI O, FROSSARD P. Analysis of classifiers' robustness to adversarial perturbations[J/OL]. Available: <http://arxiv.org/abs/1502.02590>.
- [9] SCHWENK H, BOUGARER F, BARRAULT L. Efficient training strategies for deep neural network language models[C]// *NIPS workshop on Deep Learning and Representation Learning*. 2014.
- [10] ZEILER M D, KRISHNAN D, TAYLOR G W, et al. Deconvolutional networks[C]// *2010 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2010; 2528-2535.
- [11] KAVUKCUOGLU K, SERMANET P, BOUREAU Y, et al. Learning convolutional feature hierarchies for visual recognition[C]// *Proceedings of Advances in Neural Information Processing Systems*, 2010. New York: Curran Associates, Inc., 2010; 1090-1098.
- [12] ZEILER M D, TAYLOR G W, FERGUS R. Adaptive deconvolutional networks for mid and high level feature learning[C]// *2011 IEEE International Conference on Computer Vision (ICCV)*. IEEE, 2011; 2018-2025.
- [13] DOSOVITSKIY A, BROX T. Inverting Visual Representations with Convolutional Networks[J]. *arXiv preprint arXiv:1506.02753*, 2015.
- [14] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks[M]// *Computer Vision-ECCV 2014*. Springer International Publishing, 2014; 818-833.
- [15] YOSINSKI J, CLUNE J, NGUYEN A, et al. Understanding neural networks through deep visualization[J]. *arXiv preprint arXiv:1506.06579*, 2015.
- [16] BOUREAU Y L, PONCE J, LECUN Y. A Theoretical Analysis of Feature Pooling in Visual Recognition [C] // *International Conference on Machine Learning*. 2010; 459-459.
- [17] FARABET C, COUPRIE C, NAJMAN L, et al. Learning hierarchical features for scene labeling[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2013, 35 (8): 1915-1929.
- [9] ZHANG M, ZHANG J, SU J, et al. A composite kernel to extract relations between entities with both flat and structured features[C]// *Proceedings of the 21st International Conference on Computational Linguistics and the 44th Annual Meeting of the Association for Computational Linguistics*. Sydney, 2006; 825-832.
- [10] HUANG R, SUN L, FENG Y. Study of kernel-based methods for Chinese relation extraction[M]// *Lecture Notes in Computer Science; Information Retrieval Technology*. 2008; 598-604.
- [11] BENGIO Y. Learning deep architectures for AI[J]. *Foundations and trends® in Machine Learning*, 2009, 2(1): 1-127.
- [12] KAUTZ H, SELMAN B, SHAH M. The hidden Web[J]. *AI magazine*, 1997, 18(2): 27.
- [13] MIKA P. Flink; Semantic web technology for the extraction and analysis of social networks[J]. *Web Semantics; Science, Services and Agents on the World Wide Web*, 2005, 3(2): 211-223.
- [14] CHANG J, BOYD-GRABER J, BLEI D M. Connections between the lines; augmenting social networks with text [C]// *Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. Paris, France, 2009; 169-178.
- [15] 姚从磊, 邱楠. 一种基于 Web 的大规模人物社会关系提取方法 [J]. *模式识别与人工智能*, 2007, 20(6): 740-744.
- [16] JING H, KAMBHATLA N, ROUKOS S. Extracting social networks and biographical facts from conversational speech transcripts[C]// *Proceedings of the 45th Annual Meeting of the Association of Computational Linguistics*. Prague, 2007; 1040-1047.
- [17] ELSON D K, DAMES N, MCKEOWN K R. Extracting social networks from literary fiction[C]// *Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics*. PA, USA, 2010; 138-147.
- [18] VAN DE CAMP M, VAN DEN B A. A link to the past; constructing historical social networks[C]// *Proceedings of the 2nd Workshop on Computational Approaches to Subjectivity and Sentiment Analysis*. Portland, Oregon, 2011; 61-69.
- [19] 郭振, 张玉洁, 苏晨, 等. 基于字符的中文分词, 词性标注和依存句法分析联合模型[J]. *中文信息学报*, 2014, 28(6): 1-8.
- [20] 郭喜跃, 何婷婷, 胡小华, 等. 基于句法语义特征的中文实体关系抽取[J]. *中文信息学报*, 2014, 28(6): 183-189.

(上接第 145 页)